

ANALISIS DE TEST A/B

Sistema de recomendaciones

Evaluacion del experimento recommender_system_test — conclusiones y recomendacion de negocio

CONTEXTO

1. Objetivo del test A/B

Evaluar si un nuevo sistema de recomendaciones (grupo B) mejora la conversion de usuarios en el embudo **login → product_page → product_cart → purchase**, frente al sistema actual (grupo A), con una mejora esperada de al menos **10%** en las etapas clave.

Parametro	Valor esperado
Region objetivo	EU
Periodo de registro	2020-12-07 a 2020-12-21
Periodo de eventos	2020-12-07 a 2021-01-01
Ventana de analisis por usuario	14 dias desde registro
Participantes esperados	6,000 (15% de nuevos usuarios EU)
Nivel de significancia	alpha = 0.05

2. Que tan confiable es el experimento?

3,481

usuarios validos vs. 6,000 esperados (58%)

887

usuarios participando en mas de un test A/B

2,604 / 877

usuarios en grupo A / B — desbalance 75% / 25%

0

usuarios asignados a mas de un grupo dentro del test (correcto)


La muestra final quedo muy por debajo de lo planeado y con grupos desbalanceados, lo cual reduce la potencia estadistica del grupo B.

3. Campanas de marketing solapadas

Campana	Regiones	Inicio	Fin	Solapa con el test?
Christmas & New Year Promo	EU, N.America	2020-12-25	2021-01-03	Si, region EU
CIS New Year Gift Lottery	CIS	2020-12-30	2021-01-07	No aplica (region distinta)

La campana de Navidad y Ano Nuevo coincide con la **region objetivo (EU)** y con el **tramo final del periodo de analisis**, lo que pudo alterar el comportamiento de compra de ambos grupos por igual, dificultando aislar el efecto puro del sistema de recomendaciones.

4. Eventos por usuario: A vs B



6 vs 4


mediana de eventos por usuario (A vs B)

$p \approx 1.03e-20$

Mann-Whitney U: diferencia altamente significativa


El grupo B no solo convierte menos: en general genera **menos actividad total** por usuario. No es una etapa aislada del embudo, es un patron sistematico.

5. Eventos diarios por grupo



El volumen de eventos del grupo B es consistentemente menor al de A durante todo el periodo, sin picos anómalos que sugieran errores de registro.

6. Embudo de conversion: A vs B



El grupo B queda por debajo del grupo A en las **cuatro** etapas del embudo. No se observa la mejora del 10% esperada; el efecto va en la direccion contraria.

7. Prueba Z de proporciones

Etapas	Conv. A	Conv. B	Lift B vs A	p-value	Sig. (a=0.05)	Sig. Bonferroni (a=0.0125)
login	100.00%	99.89%	-0.11%	0.0848	No	No
product_page	64.71%	56.21%	-13.13%	0.000007	Si	Si
product_cart	30.03%	27.82%	-7.35%	0.2147	No	No
purchase	31.99%	28.39%	-11.24%	0.0465	Si	No

Al corregir por comparaciones multiples (Bonferroni, alpha=0.0125), solo **product_page** se mantiene significativo — y el efecto es negativo para el grupo B.

CONCLUSION

8. El test no fue exitoso

- El grupo B **no mejora** la conversion en ninguna etapa del embudo.
- La caida en **product_page** es estadisticamente significativa incluso tras corregir por comparaciones multiples.
- Ademas de los resultados, el experimento tiene **problemas de diseno**: muestra insuficiente (58% de lo planeado), grupos desbalanceados (75/25), usuarios compartidos con otros tests (887) y una campana de marketing solapada con la region objetivo.
- Estos factores no explican por si solos el resultado, pero exigen prudencia antes de atribuir la caida unicamente al sistema de recomendaciones.

9. Que deberia hacer el equipo de producto

No liberar el cambio a produccion con la evidencia actual: el riesgo de empeorar la conversion ya se observo en los datos.

Repetir el test A/B corrigiendo la asignacion (grupos balanceados 50/50), excluyendo usuarios en tests simultaneos, y evitando ventanas con campanas activas en la region objetivo.

Si el resultado se repite con un diseno correcto, el sistema de recomendaciones necesita rediseño antes de una nueva prueba.